

班 级 2203018

学 号 22009290006

西安电子科技大学

本科毕业设计论文



题 目 面向标注稀缺的医学图像自适应分割

理论与方法研究

学 院 计算机科学与技术学院

专 业 计算机科学与技术

学生姓名 杨尚霖

导师姓名 权义宁

摘 要

医学图像分割是辅助疾病诊断与治疗规划的关键环节，但其深度学习方法的发展长期受限于高质量标注数据的匮乏。临床标注过程不仅耗时费力，不同医疗机构之间的数据分布也差异显著，这使得现有模型在跨中心、跨模态场景下泛化性能较差，难以真正落地应用。

针对标注稀缺与模型泛化能力不足这两个核心问题，本研究系统构建了一套自适应的医学图像分割理论与方法体系。一方面，为提升有限标注数据的利用效率，设计了认知不确定性引导的半监督学习框架，通过量化模型预测的不确定性来优化伪标签质量；另一方面，为增强模型对多尺度特征的提取能力，深入探究了 U-Net 与 Transformer 的融合范式，并在网络的跳跃连接中引入通道注意力机制，以强化关键特征的传递。

为验证所提方法的有效性，本研究基于 CA 数据集与 Synapse 数据集开展了系列对比实验。在半监督实验部分，所提 UA-MT 框架仅使用 20% 的有标签数据（16 例）即可达到 88.18% 的 Dice 系数，显著优于标准 Mean Teacher 方法。在网络架构实验部分，引入双重注意力机制的 DA-TransUNet 模型在多器官分割任务中取得了 80.67% 的平均 Dice 系数，且边界分割精度（HD95）明显优于 U-Net 及 Swin-Unet 等基准模型。上述结果表明，本研究提出的方法能够有效缓解标注数据稀缺带来的瓶颈，并显著提升分割精度与模型鲁棒性。

关键词：医学图像分割 半监督学习 标注稀缺样本 自适应分割

ABSTRACT

Medical image segmentation is a critical component in assisting disease diagnosis and treatment planning. However, the development of deep learning methods in this field has long been constrained by the scarcity of high-quality annotated data. The clinical annotation process is not only time-consuming and labor-intensive, but the distribution of data also varies significantly across different medical institutions. This leads to poor generalization performance of existing models in cross-center and cross-modal scenarios, making them difficult to deploy effectively in real-world applications.

To address these two core challenges—annotation scarcity and insufficient model generalization—this study systematically constructs an adaptive theoretical and methodological framework for medical image segmentation. On one hand, to improve the utilization efficiency of limited annotated data, a cognitive uncertainty-guided semi-supervised learning framework is designed, which optimizes pseudo-label quality by quantifying the uncertainty of model predictions. On the other hand, to enhance the model’s ability to extract multi-scale features, the fusion paradigm of U-Net and Transformer is thoroughly investigated, and a channel attention mechanism is introduced into the skip connections of the network to reinforce the transmission of critical features.

To validate the effectiveness of the proposed methods, a series of comparative experiments are conducted on two datasets: the CA dataset and the Synapse dataset. In the semi-supervised experiment, the proposed UA-MT framework achieves a Dice coefficient of 88.18% using only 20% of labeled data (16 cases), significantly outperforming the standard Mean Teacher method. In the network architecture experiment, the DA-TransUNet model, which incorporates a dual attention mechanism, attains an average Dice coefficient of 80.67% on the multi-organ segmentation task, with boundary segmentation accuracy (HD95) clearly surpassing baseline models such as U-Net and Swin-Unet. These experimental results demonstrate that the proposed methods can effectively alleviate the bottleneck caused by scarce annotated data while substantially improving segmentation accuracy and model robustness.

Keywords: Medical Image Segmentation Semi-supervised Learning Annotation-
scarce Samples Adaptive Segmentatio

目 录

第一章 绪论	1
1.1 国内外研究现状	1
1.1.1 国内研究现状	1
1.1.2 国外研究现状	1
1.2 背景介绍	2
1.2.1 机器学习范式：监督、无监督与半监督	3
1.2.2 深度学习与神经网络概述	3
1.3 论文主要工作	4
1.4 论文章节安排	5
第二章 相关理论基础	7
2.1 认知不确定性理论	7
2.1.1 认知不确定性的定义与成因	7
2.1.2 认知不确定性的度量方法	7
2.2 Transformer 架构原理	8
2.2.1 自注意力机制	8
2.2.2 Vision Transformer 与 Swin Transformer	8
第三章 基于认知不确定性的半监督方法研究	10
3.1 整体框架概述	10
3.2 Mean Teacher 框架	10
3.2.1 Mean Teacher 基本原理	10
3.2.2 Mean Teacher 的优势与局限	11
3.3 UA-MT 框架构建与不确定性引入	12
3.3.1 UA-MT 框架设计思路	12
3.3.2 基于蒙特卡洛 Dropout 的认知不确定性建模	12
3.3.3 基于不确定性图的一致性损失	13
3.3.4 不确定阈值动态选取	14
3.4 实验设计	15
3.4.1 数据集与预处理	15

3.4.2	网络架构与训练策略	15
3.5	对比与结果分析	15
3.5.1	不同模型检测性能对比实验分析	15
3.5.2	消融实验	16
第四章	基于 Transformer 的多尺度自适应表示学习模型	18
4.1	整体框架概述	18
4.2	基础模型选择 (U - Net)	18
4.2.1	U-Net 结构解析	18
4.2.2	U-Net 的优势与局限	19
4.3	Transformer 引入与融合策略	20
4.3.1	Swin - Unet 模型	20
4.3.2	TransUnet 模型	22
4.3.3	DA - TransUnet 改进模型	24
4.4	实验设计	26
4.4.1	数据集与预处理	26
4.4.2	训练策略	27
4.5	对比与结果分析	27
4.5.1	不同模型检测性能对比实验分析	27
4.5.2	消融实验分析	28
第五章	总结与展望	30
5.1	论文所完成的工作	30
5.2	问题与不足	31
5.3	前景与展望	31
	致谢	33
	参考文献	34

第一章 绪论

1.1 国内外研究现状

医学图像分割是计算机辅助诊断系统中的关键技术之一，近年来随着深度学习技术的快速发展，基于全监督学习的分割方法在多个公开数据集上取得了显著成果。然而，这些方法高度依赖大量精确标注的数据，而在医学影像领域，高质量的标注数据通常稀缺且获取成本高昂，严重制约了模型在真实临床场景中的推广与应用。同时由于分割任务的不同，往往需要采用不同的特定分割网络，这大大增加了分析成本以及训练成本，需要一种能融合多尺度信息的通用网络框架。

1.1.1 国内研究现状

国内研究团队在医学图像分割领域已取得一系列进展。例如：DTC^[1]采用多个独立的分割网络构成协同训练小组，让它们互为师生、通过视觉摘要和预测分歧相互监督，从而高效挖掘无标签数据中的互补信息；SASSNet^[2]将形状先验知识显式地建模为一个并行的形状流网络，通过强制分割预测与学习到的形状表示在潜在空间中对齐，确保模型对无标签数据的输出不仅在像素级别准确，同时符合解剖结构的整体合理性。

CA-Net^[3]通过空间、通道及尺度三重注意力机制逐步细化分割结果，并结合课程学习策略从易到难学习病灶特征，显著提升了胰腺、肝脏等复杂解剖结构的分割稳定性；TransFusion^[4]通过交叉注意力机制动态整合不同成像模态的特征表示，在病灶边界模糊、模态信息不匹配情况下仍能保持分割一致性，显著提升了多模态数据协同分析的鲁棒性。

1.1.2 国外研究现状

国外在医学图像分割领域的研究起步较早，尤其在自适应学习、半监督与自监督学习方面进展显著。例如：Mean Teacher^[5]通过平均学生模型的权重来生成更稳定的教师模型，利用一致性损失提升半监督学习的效果；MixMatch^[6]将多张有标签和无标签数据在图像和标签空间同时进行混合，并对无标签数据产生强化后的“猜测标签”，从而在一个损失中统一优化所有数据。

UNETR^[7]首次将标准的 Vision Transformer 直接扩展为 3D 医学图像分割的编码器骨干网络，通过将体积图像分割为三维补丁序列并输入 Transformer，以直接建模图像中任意两个体素之间的长距离全局依赖，再通过一个专用的卷积解码器

逐步上采样和恢复空间细节，实现了对复杂解剖结构的全局上下文与局部空间一致性的统一建模；nnUNet^[8]通过一个高度自动化的框架，系统化地优化数据预处理、训练策略和后处理流程，使标准的 U-Net 架构在不同医学图像数据集上都能达到或超越许多定制化模型的性能，强调了工程化流程的重要性。

1.2 背景介绍

近年来，深度学习理论与技术发展迅速。医学图像分割作为计算机辅助诊断的核心环节之一，在病灶定位、器官重建及手术规划中扮演着重要角色。不过，当前该领域仍面临两大核心挑战，也正是本文着力要解决的问题。

第一个挑战来自标注数据。高质量的医学图像标注成本很高，离不开资深医生的专业知识与手工勾画，既费时又费力。由此带来的标注数据稀缺和标注代价昂贵，严重制约了深度学习模型的泛化能力。如何利用大量未标注的医学图像，借助半监督学习策略挖掘数据中隐含的信息，已成为当前研究的热点和难点。但传统半监督方法往往忽略模型在预测过程中的可靠性评估，导致无标签数据中的噪声反过来干扰训练。

第二个挑战来自网络结构。以 U-Net 为代表的主流分割网络大多基于卷积神经网络（CNN）。CNN 的局部感受野特性限制了它对长距离依赖关系的建模能力，也使其难以根据输入的病理特征进行自适应推理。在处理背景复杂、边界模糊的医学图像时，这类模型容易出现细节丢失或误分割。近年来，Transformer 架构在自然语言处理领域取得巨大成功后，逐渐被引入计算机视觉领域。其强大的全局建模能力为上述问题提供了新的解决思路，但如何将其有效融入医学图像分割框架，并与传统卷积网络形成优势互补，仍需深入探索。

基于上述背景，本文聚焦于医学图像分割任务，从两个关键维度展开研究。一是引入认知不确定性理论，通过改进 Mean Teacher 等半监督框架，使模型能够识别并抑制无标签数据中的不可靠预测，从而提升数据稀缺情况下的模型鲁棒性。二是探索 Transformer 架构的引入机制，构建能够同时捕获局部细节与全局上下文信息的混合模型，以增强分割的边界精度和对复杂结构的解析能力。这两条技术路线的并行推进，旨在为高精度、低标注成本的医学图像分析提供有效的解决方案。

接下来我将介绍几个基础概念，以进行对本文内容的补充与完善。

1.2.1 机器学习范式：监督、无监督与半监督

在机器学习领域，根据数据属性和学习目标的不同，可以将学习方法主要划分为三大基本范式：监督学习、无监督学习和半监督学习。这三种范式构成了数据挖掘与模式识别的理论基石，各自适用于不同的应用场景，并解决不同类型的现实问题。

监督学习是机器学习中最成熟、应用最广泛的范式。其核心思想是利用带有标签的训练数据集来学习一个从输入到输出的映射函数。所谓“标签”，即数据的已知结果或类别（如价格预测任务中某个房子具体的价格，或图像分类任务中的“猫”或“狗”）。在训练过程中，模型通过不断比较预测输出与真实标签之间的差异，调整内部参数以最小化误差。而在本文所进行的研究中，监督学习主要是作为性能基准，用于评估和对比半监督学习在利用无标签数据后所带来的性能提升效果。

与监督学习相对，无监督学习处理的是没有标签的原始数据。其主要目标不是进行预测，而是探索数据内部隐藏的结构、模式或分布。无监督学习不需要预先定义输出结果，而是通过算法自动发现数据的内在关联。在本文中由于没有对无监督学习的应用，便不多进行赘述。

半监督学习则介于上述两者之间，它试图结合少量的标注数据和大量的未标注数据进行模型训练。在现实世界中，获取大量精确标注的数据往往成本高昂且耗时（如医学影像标注），而未标注的数据则相对容易获得。半监督学习通过利用未标注数据的分布信息，辅助标注数据构建更鲁棒、泛化能力更强的模型。其基本假设通常是：数据具有一定的内在结构（如聚类假设或流形假设），即相近的数据点倾向于拥有相同的标签，以此对模型进行训练。本文在第三章中将对该方法进行具体的详细阐述与实验验证。”

1.2.2 深度学习与神经网络概述

深度学习作为机器学习的一个重要分支，其核心机制是利用深层神经网络来模拟人脑处理信息，从而实现对数据的多层次抽象与特征学习。它在传统神经网络的基础上进行了继承与发展：神经网络构成了深度学习的基础架构，而深度学习则通过引入更深的网络层次和更复杂的非线性变换，赋予了模型提取更高层次、更复杂特征的能力。

人工神经网络（Artificial Neural Network, ANN）受生物神经系统启发，主要由

大量相互连接的“神经元”节点组成。一个基本的神经元模型接收输入特征向量 x ，通过加权求和并加上偏置项 b ，再经过非线性激活函数产生输出。

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) \quad (1-1)$$

其中 w_i 为连接权重，代表输入特征的重要性。通过调整权重和偏置，神经网络能够学习输入与输出之间的复杂映射关系。典型的网络结构包含输入层、隐藏层和输出层；随着隐藏层数量的增加，网络的表达能力显著增强。

深度学习模型的训练是一个通过数据驱动来自动调整内部参数的迭代优化过程，其核心目标是最小化模型预测输出与真实标签之间的误差。该过程主要包含以下四个关键步骤：

前向传播：数据从输入层进入网络，逐层经过加权求和与非线性激活函数的计算，最终在网络的输出层产生预测结果。这一过程将输入数据映射为模型的预测输出。

损失计算：利用损失函数来量化模型预测值与真实标签之间的差距。损失函数的值被称为“损失”（Loss）或“误差”（Error），训练的目标即是最小化这一数值。

反向传播：这是训练深层网络的核心步骤。它从输出层开始，将损失值沿着网络结构反向传递。通过计算损失函数对每个网络参数（权重 w 和偏置 b ）的偏导数，从而明确参数更新的方向。

参数更新：在获取了参数的梯度后，优化器会使用这些信息来更新网络参数。最基础的更新规则是梯度下降法，其核心思想是让参数沿着梯度的反方向（即损失减小最快的方向）进行调整。更新公式可表示为：

$$w_{\text{new}} = w_{\text{old}} - \eta \cdot \nabla_w \quad (1-2)$$

其中， w_{new} 和 w_{old} 分别代表更新后和更新前的权重， ∇_w 是损失函数对权重的梯度，而 η 则是学习率。学习率是一个关键的超参数，它控制着参数更新的步长。

通过反复执行上述“前向传播 → 损失计算 → 反向传播 → 参数更新”的循环，模型能够逐步学习到数据中的内在规律，使其预测能力不断提升。

1.3 论文主要工作

在半监督医学图像分割领域，如何有效利用大量未标注数据以缓解对昂贵标注数据的依赖，已成为当前研究的热点与难点。深入挖掘未标注数据中的隐含信

息有利于提升模型在复杂场景下的泛化能力。然而，现有的半监督方法在训练过程中往往忽略了模型对预测结果的可信度评估，导致在迭代过程中容易产生错误累积（即确认偏差）或对噪声过度信赖。同时，传统的卷积神经网络（CNN）在捕捉长距离依赖关系方面存在局限，而直接引入 Transformer 架构虽然增强了全局建模能力，但如何高效地融合局部细节与全局语义信息仍是一个挑战。

对于上述半监督分割算法中的问题，我们需要对模型的不确定性进行建模以指导训练过程，并对不同的网络架构进行消融实验以验证其有效性，所以本文的主要工作是：

（1）引入认知不确定性的半监督学习范式：将认知不确定性引入 Mean Teacher 模型中，利用蒙特卡洛 Dropout 估计预测的不确定度，并将其作为权重融入一致性损失函数，从而抑制高不确定性样本对模型更新的负面影响；

（2）构建并对比多种 CNN-Transformer 混合架构：在 U-Net 的基础上结合 Transformer，实现了 Swin-Unet 和 TransUnet 两种不同的结合方式，并在此基础上进一步引入 DA-TransUnet 的跳跃连接注意力机制，对这四种模型（U-Net baseline, Swin-Unet, TransUnet, DA-TransUnet）进行了系统的对比分析；

（3）定量评价模型性能：在标准测试集上对算法结果进行定量评价（如 Dice 系数、Hausdorff 距离）并对不同的模型结构进行评价。

1.4 论文章节安排

本论文围绕半监督医学图像分割中的不确定性建模与网络架构优化展开研究，旨在提升模型在有限标注数据下的鲁棒性与分割精度。全文共分为五个章节，具体组织结构如下：

第一章：绪论。首先介绍机器学习的基本范式，重点阐述半监督学习在医学图像分析领域的研究背景与应用价值。随后概述深度学习与神经网络的基本概念，明确本文的主要研究工作，并给出整体章节安排。

第二章：相关理论基础。系统介绍支撑本文研究工作的核心理论。先详细阐述认知不确定性理论，包括其定义、成因及常用度量方法；再深入剖析 Transformer 架构的原理，重点拆解自注意力机制，并介绍 Vision Transformer 与 Swin Transformer 在视觉任务中的应用，为后续模型设计打下理论基础。

第三章：基于认知不确定性的半监督方法研究。聚焦半监督学习框架的改进。先介绍 Mean Teacher 框架的基本原理，然后重点阐述 UA-MT（不确定性感知的

Mean Teacher) 框架的构建过程及其不确定性引入机制。通过设计相应实验, 利用特定数据集与评价指标对算法性能进行对比验证与结果分析。

第四章: 基于 Transformer 的多尺度自适应表示学习模型。详细介绍网络模型的搭建与融合策略。首先选定 U-Net 作为基础模型, 接着探讨 Transformer 的引入方式, 具体涵盖 Swin-Unet、TransUnet 以及改进后的 DA-TransUnet 模型。最后通过系统的实验设计, 评估并对比不同模型在相同环境下的表现。

第五章: 总结与展望。对全文研究工作进行全面总结, 归纳论文取得的主要成果。同时, 客观指出当前研究存在的不足, 并对未来可能的研究方向及应用前景进行探讨。

第二章 相关理论基础

为有效解决绪论中提出的模型预测可信度评估问题以及模型在长距离依赖捕捉与任务自适应学习方面不足的问题，本章系统性地阐述了研究所依赖的核心理论框架，主要是相关的理论基础。一方面，通过梳理认知不确定性理论的定义、成因及度量手段，确立了评估模型预测结果置信度的理论依据；另一方面，通过对 Transformer 架构的理解与剖析，也能更深刻的理解 Transformer 能解决相关问题的内在原因。上述理论基础的建立，不仅完善了本文的知识体系，也为后续章节的创新性研究提供了关键的理论支撑。

2.1 认知不确定性理论

在深度学习与统计领域，模型的预测不仅需要准确性，更需要具备对自身预测能力的“自知之明”——即能认识到自己有多大的把握确认自己的判断。认知不确定性正是用来刻画这种“无知程度”的概念，它源于模型对输入数据知识的缺乏，反映了参数层面的不确定性。本节将阐述其定义与主流度量方式。

2.1.1 认知不确定性的定义与成因

认知不确定性，又称知识不确定性，是指由于训练数据覆盖不足、模型表达能力受限等原因，使模型在面对未知分布样本时产生的预测歧义性。其本质在于模型参数所具有的不确定性——即在给定数据下，存在多个参数配置均能较好拟合观测，但对新样本给出不同预测。从贝叶斯视角看，若将模型参数 w 视为随机变量，认知不确定性即来源于后验分布 $p(w | D)$ 的弥散程度：分布越分散，说明数据对参数的约束越弱，模型认知越模糊。

其成因主要有三方面。一是数据稀缺性：输入空间的某些区域缺乏足够标注样本，模型难以学到有效的决策边界。二是模型表达局限性：即便数据充足，结构固定的网络模型也可能无法捕捉复杂的非线性映射。三是路径依赖：随机梯度下降等算法可能收敛到不同的局部最优解，从而加剧预测的不一致性。

2.1.2 认知不确定性的度量方法

对认知不确定性的量化主要依赖于对模型参数分布的近似推断。主流方法是通过采样来估计预测分布的离散程度。其中，蒙特卡洛 Dropout 作为一种高效实用的方法，通过在测试阶段多次启用 Dropout 进行前向传播，生成一组 Softmax 概率

向量 $\{\mathbf{p}_t\}_{t=1}^T$ ，进而估计不确定性：

$$\mu_c = \frac{1}{T} \sum_{t=1}^T \mathbf{p}_t^c, \quad u = - \sum_c \mu_c \log \mu_c$$

该方法的理论基础在于将 Dropout 视为对贝叶斯后验的变分近似，从而将认知不确定性与随机不确定性解耦。另一种重要范式是深度集成，通过训练多个独立初始化的模型并集成其预测，由于本文并没有使用该方法，故不进行详细介绍。

2.2 Transformer 架构原理

2.2.1 自注意力机制

自注意力机制（Self-Attention Mechanism）是 Transformer 架构的核心，它通过计算序列中不同位置元素之间的关联权重，实现对全局依赖关系的建模。其本质是将输入序列映射为查询（Query, Q ）、键（Key, K ）和值（Value, V ）三个矩阵，通过点积运算衡量查询与键的相似性，再利用 Softmax 函数归一化得到注意力权重，最终加权求和值矩阵以生成输出。

为缓解点积结果过大导致的梯度消失问题，通常引入缩放因子 d_k （ d_k 为键向量的维度），其核心计算公式为：

$$\text{Attention}(Q, K, V) = \text{Softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2-1)$$

为进一步提升模型的表征能力，Transformer 采用多头注意力机制，将 Q 、 K 、 V 分别投影到 h 个不同的子空间（“头”）中并行计算注意力，再将各头的输出拼接后线性变换。公式化表达为：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) W^O \quad (2-2)$$

其中，第 i 个头的计算为：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (2-3)$$

W_i^Q 、 W_i^K 、 W_i^V 为投影矩阵， W^O 为输出投影矩阵。

2.2.2 Vision Transformer 与 Swin Transformer

Vision Transformer (ViT) 将 Transformer 架构直接迁移至图像领域，核心思想是将图像分割为固定大小的图像块（Patch），并将每个图像块展平后线性投影为“视觉词元”（Visual Token），再添加位置编码（Positional Encoding）以保留空间信

息。这些词元序列被输入标准 Transformer 编码器，通过自注意力机制捕捉全局特征。

ViT 的输入处理可形式化为：设输入图像尺寸为 $H \times W \times C$ （高、宽、通道数），图像块尺寸为 $P \times P$ ，则图像块数量为 $N = \frac{HW}{P^2}$ ，每个图像块的展平向量为 $x_p \in \mathbb{R}^{P^2 \cdot C}$ ，经线性投影后得到词元：

$$x_i = W_p x_p + E_{\text{pos},i} \quad (2-4)$$

其中 W_p 为投影矩阵， $E_{\text{pos},i}$ 为位置编码。

Swin Transformer 针对 ViT 计算复杂度高的问题，提出滑动窗口机制，将自注意力计算限制在局部窗口内，同时通过窗口滑动实现跨窗口的信息交互。其核心是窗口注意力（Window Attention）和移位窗口（Shifted Window）：

窗口注意力：将特征图划分为不重叠的局部窗口（如 $M \times M$ ），在每个窗口内计算自注意力，计算复杂度由 $O(N^2)$ 降至 $O(M^2 \cdot \frac{N}{M^2}) = O(N)$ （ N 为词元数量， M 为窗口尺寸）。

移位窗口：在相邻 Transformer 层中，将窗口沿空间维度滑动 $M/2$ 个像素，使不同窗口的词元能够交互，避免局部窗口的孤立性。

Swin Transformer 还引入层次化特征图，通过逐步合并图像块构建多尺度特征，适配图像分类、检测、分割等下游任务。其窗口注意力的计算公式为：

$$\text{WindowAttention}(Q, K, V) = \text{Softmax} \left(\frac{QK^T}{\sqrt{d_k}} + B \right) V \quad (2-5)$$

其中， B 为相对位置编码（Relative Position Bias），用于建模窗口内词元的相对空间位置关系。

第三章 基于认知不确定性的半监督方法研究

3.1 整体框架概述

针对医学图像标注成本高昂、数据稀缺的核心痛点，本章旨在构建一种能够有效利用大量未标注数据的半监督分割框架。本章提出的解决方案遵循“教师-学生”（Teacher-Student）协同学习的范式，其核心思想在于利用模型对无标签数据预测的一致性来指导训练，从而减少对人工标注的依赖。

本章的整体研究框架主要包含以下三个关键环节：


1. 基线构建：首先确立 Mean Teacher 作为基础框架，通过指数移动平均 (EMA) 策略构建稳定的教师模型，并利用其为学生模型提供一致性目标。
2. 不确定性建模：针对半监督学习中伪标签噪声的问题，引入认知不确定性理论。通过蒙特卡洛 Dropout 策略量化模型预测的“无知程度”，生成体素级的不确定性图。
3. 损失函数优化：将不确定性图作为权重引入一致性损失函数，构建不确定性感知的一致性损失（Uncertainty-Aware Consistency Loss）。该机制能够有效抑制高不确定性区域（如模糊边界或噪声）对模型更新的干扰，引导学生模型仅从高置信度区域进行学习。
4. 通过上述设计，本章提出的 UA-MT（Uncertainty-Aware Mean Teacher）框架能够在仅使用少量标注数据的情况下，充分挖掘无标签数据中的潜在价值，显著提升模型的鲁棒性与泛化能力。

3.2 Mean Teacher 框架

3.2.1 Mean Teacher 基本原理

Mean Teacher 框架是一种基于一致性正则化的半监督学习方法，其核心思想在于通过指数移动平均的方式更新教师模型的权重，并利用学生模型与教师模型之间的协同训练机制来提升模型性能。

具体而言，如图 3.1 所示，学生模型（Student）和教师模型（Teacher）接收同一个输入 x ，并分别加上不同的噪声 η 和 η' 。随后，学生模型的 Softmax 输出将用于计算两部分损失：(1) 与真实标签（One-hot label）计算交叉熵损失；(2) 与教师模型的输出计算一致性损失 $J(\theta)$ 。总损失根据预设权重加权后，用于更新学生模

图 3.1 Mean Teacher 框架结构图^[5]

型。

在学生模型权重更新后，教师模型的权重通过指数移动平均（EMA）策略进行更新。权重更新规则可表示为：

$$\theta'_t = \alpha \theta'_{t-1} + (1 - \alpha) \theta_t \quad (3-1)$$

其中， α 为 EMA 系数，通常取接近 1 的值。这种系数的设定使得教师模型能够提供更加平滑的输出，从而为学生模型提供高质量的伪标签信息。此外，Mean Teacher 框架还引入了一致性损失函数，用于约束学生模型与教师模型在输入数据经过扰动后的输出一致性。设学生模型输出为 y ，教师模型输出为 y' ，则一致性损失 $L_{\text{consistency}}$ 可定义为两者的均方误差：

$$L_{\text{consistency}} = \|y - y'\|^2 \quad (3-2)$$

这进一步增强了对未标记数据的利用率。从理论角度来讲，该方法的有效性可归因于其对模型输出的平滑性假设以及熵最小化原则的结合。

3.2.2 Mean Teacher 的优势与局限

Mean Teacher 框架在半监督学习和语义分割任务中表现出不少优势，但也有一些固有的局限。

从优势来看。第一，该框架借助教师模型与学生模型的协同训练，能有效利用未标注数据，因此在标注数据有限的条件下仍能显著提升模型性能。第二，教师模型的权重采用指数移动平均方式更新，这种机制能在一定程度上抑制某些特

殊样本对模型产生过大扰动，使输出结果更为稳定可靠。第三，一致性损失函数的引入增强了模型对数据扰动的鲁棒性，在一定程度上缓解了过拟合问题。

不过，尽管 Mean Teacher 框架性能表现不错，它的局限性也比较明显。例如，它对计算资源的要求较高，尤其是在处理大规模数据集时，训练时间的增加可能成为制约实际应用的主要瓶颈。另外，由于需要同时维护教师和学生两套模型的参数，内存占用大约是单个模型的两倍。

3.3 UA-MT 框架构建与不确定性引入

3.3.1 UA-MT 框架设计思路

针对传统 Mean Teacher 框架在处理复杂语义分割任务时的局限，本文采用了 UA-MT^[9] 框架。该框架的核心思路是把认知不确定性建模融入到 Mean Teacher 的一致性正则化机制当中。

在标准 Mean Teacher 方法里，学生模型被强制去拟合教师模型的输出。这种拟合方式带有一定的“盲目性”——不管教师模型的预测准不准，学生都得跟着学。为了解决这个问题，UA-MT 引入了不确定性感知机制。具体来说，它借助蒙特卡洛 Dropout 估算出教师模型预测中的认知不确定性，然后把这个不确定性作为权重放进一致性损失函数里。


这一设计让学生模型在训练时能做到“有选择”地学习：在教师模型预测置信度高的区域，学生模型就严格跟着学；而在教师模型自己也拿不准的模糊区域，就相应降低那一部分对一致性损失的贡献，避免被错误引导。通过这种机制，UA-MT^[9] 能更充分地利用无标签数据，提升模型在复杂场景下的鲁棒性和泛化能力。

3.3.2 基于蒙特卡洛 Dropout 的认知不确定性建模

在语义分割任务中，模型的不确定性通常来自对模糊边界或相似类别的“认不清”。为了把这部分不确定性量化出来，本研究让教师模型同时生成一张不确定性评估图。具体做法是：在推理阶段保持 Dropout 层开启，对同一个输入数据做多次随机前向传播，用蒙特卡洛采样的方式来近似模型的后验分布。

如图 3.2 所示，该图为 UA-MT 框架图。具体而言，对于每一个输入体素，我们进行 T 次前向传播。设第 t 次传播中，模型预测该体素属于第 c 类别的概率为 p_t^c 。为了获得稳健的不确定性估计，我们首先计算该体素在 T 次采样中的平均预测概率 μ_c ：

$$\mu_c = \frac{1}{T} \sum_{t=1}^T p_t^c \quad (3-3)$$

图 3.2 UA-MT 框架结构图^[9]

其中， μ_c 代表了模型对该体素属于类别 c 的平均置信度。基于此平均概率分布，我们采用预测熵来量化不确定性。对于每一个体素，其不确定性得分 u 定义为：

$$u = - \sum_c \mu_c \log \mu_c \quad (3-4)$$

该公式通过计算平均概率分布的熵来衡量模型的“犹豫”程度。当 μ_c 在各个类别间分布均匀时（即模型在多次预测中摇摆不定），熵值 u 较高，表示高不确定性；反之，若模型始终倾向于某一类别，则 u 较低。

通过对图像中每一个体素重复上述计算，最终可以构建出一个与输入数据空间维度一致的不确定性张量 $\mathcal{U}$ 。若输入数据的维度为 $H \times W \times D$ ，则不确定性张量表示为：

$$\mathcal{U} \in \mathbb{R}^{H \times W \times D} \quad (3-5)$$

3.3.3 基于不确定性图的一致性损失

在估计出不确定性图 $\mathcal{U}$ 的指导下，我们需要过滤掉高不确定性的预测，仅选择置信度较高的区域作为学生模型学习的目标。

特别地，对于半监督分割任务，我们将不确定性感知一致性损失 $\mathcal{L}_c$ 设定为教师模型和学生模型在确定性较高区域的体素均方误差（MSE）损失。该损失函数定义如下：

$$\mathcal{L}_c(f', f) = \frac{\sum_v \mathbb{I}(u_v < H) \|f'_v - f_v\|^2}{\sum_v \mathbb{I}(u_v < H)} \quad (3-6)$$

式中各符号含义如下：

$\mathbb{I}(\cdot)$ 为指示函数，当条件满足时值为 1，否则为 0，用来筛选高置信度像素点。

f'_v 和 f_v 分别是教师模型和学生模型在第 v 个体素处的预测输出。

u_v 是第 v 个体素处的估计不确定性得分。

H 是预设的阈值，用于确定哪些区域被筛选。

通过引入该阈值 H ，损失函数仅在不确定性低于该阈值的体素上计算误差。随着训练过程中不确定性感知一致性损失的作用，学生模型和教师模型都可以专注于学习更可靠的知识，从而逐步降低模型的整体不确定性。

3.3.4 不确定阈值动态选取

在基于不确定性图的一致性损失计算中，阈值 H 的选取对模型性能至关重要。若 H 过小，可能导致大量包含有效信息的边界区域被丢弃；若 H 过大，在训练初期模型预测不稳定时，可能会引入大量噪声预测，误导学生模型学习。

为了平衡训练的稳定性与渐进式学习的需求，本文采用了一种基于 Sigmoid 策略的动态阈值选取机制。该机制根据训练迭代次数 t ，自动调整不确定性阈值 $H(t)$ ，其计算公式如下：

$$H(t) = [\alpha + \beta \cdot R(t)] \cdot \log(C) \quad (3-7)$$

式中：

$R(t)$ 为 Sigmoid 增长函数 (Sigmoid Rampup)，定义为 $R(t) = \frac{1}{1 + \exp(-\gamma \cdot (t - t_{mid}))}$ ，该函数在训练初期接近 0，并随迭代次数增加平滑过渡至 1。

$\log(C)$ 为归一化基准值，即多分类任务中模型预测完全随机（均匀分布）时的信息熵最大值。其中 C 为类别数。

α 和 β 为控制曲线范围的超参数。

具体而言，在本实验中，我们设定 $\alpha = 0.75$ ， $\beta = 0.25$ 。这意味着阈值 H 的取值范围被限制在 $[0.75 \log(C), \log(C)]$ 之间。在训练初期，阈值较低，允许模型利用更多相对确定的区域进行学习；随着训练进行， $R(t)$ 增大，阈值逐渐逼近完全随机熵 $\log(C)$ ，迫使模型在后期仅利用极高置信度的预测进行一致性正则化，从而有效避免了低质量伪标签对模型的干扰。

3.4 实验设计

3.4.1 数据集与预处理

本实验采用 2018 年左心房 (LA) 分割挑战赛公开数据集进行实验验证。该数据集包含 80 例 3D 图像作为训练集, 以及 20 例作为独立测试集。

为了验证框架在标注稀缺样本场景下的性能, 我们将原始的 80 例训练数据划分为两部分:

有标签集 (Labeled Set): 仅选取 16 例样本作为有监督信号来源。

无标签集 (Unlabeled Set): 剩余的 64 例样本仅提供图像, 不提供标签, 用于半监督学习。

数据预处理阶段, 我们对图像进行了归一化处理, 并采用随机裁剪 (Random Crop) 策略, 将输入块大小固定为 $112 \times 112 \times 80$ 以适应网络输入。

3.4.2 网络架构与训练策略

本实验采用 3D V-Net 作为基础分割网络架构。为了引入认知不确定性, 我们在 V-Net 的解码器部分引入了 Dropout 层, 并在推理阶段保持开启状态以进行蒙特卡洛采样。

训练参数设置如下:

优化器: 随机梯度下降 (SGD), 动量设为 0.9, 权重衰减为 0.0001。

学习率策略: 初始学习率设为 0.01, 并采用阶梯式衰减策略。

Batch Size: 每 GPU 批次大小为 4。

迭代次数: 最大迭代次数设为 6000 次。

对比方法: 为了评估 UA-MT 的有效性, 我构建了以下对比组:

Baseline (Supervised Only): 仅使用 16 例有标签数据进行全监督训练。

Mean Teacher (MT): 使用 16 例标签 + 64 例无标签数据, 标准 Mean Teacher 框架。

UA-MT (Ours): 使用 16 例标签 + 64 例无标签数据, 引入不确定性感知机制的改进框架。

3.5 对比与结果分析

3.5.1 不同模型检测性能对比实验分析

为了全面评估分割性能, 我们采用了四个广泛使用的评价指标:

1. Dice 相似系数 (Dice Coefficient): 衡量分割重叠度, 值越大越好。

- 2. Jaccard 指数 (Jaccard Index): 衡量交并比, 值越大越好。
- 3. 95% 豪斯多夫距离 (95% HD): 衡量表面最大不一致距离, 值越小越好。
- 4. 平均表面距离 (ASD): 衡量平均表面误差, 值越小越好。

表 3.1 实验对比结果

实验设置 (Method)	Dice(%)	Jaccard(%)	ASD(vox)	95HD(vox)
16 样本全监督	85.83	76.34	11.96	2.85
80 样本全监督	91.53	84.42	5.02	1.63
16+64 半监督 MT	87.25	77.74	12.73	3.31
16+64 半监督 UA-MT	88.18	79.09	12.32	3.27

结果分析:

半监督学习的有效性: 对比 Baseline (85.83%) 与 Standard MT (87.25%) 可以看到, 引入无标签数据后, Dice 系数提升了约 1.4 个百分点。这说明未标注数据确实能弥补有标签数据的不足, 有助于提升模型的泛化能力。

UA-MT 的显著优势: 将 Standard MT 与 UA-MT 放在一起比较, 无论从哪个评估指标看, 都能清楚看到引入不确定性机制所带来的增益。

重叠度指标: UA-MT 的 Dice 系数达到 88.18%, 比 Standard MT 高出 0.94%; Jaccard 指数也提升了 1.34%。这表明, 用认知不确定性对一致性损失进行加权之后, 模型能够过滤掉教师网络在高不确定区域 (比如模糊边界) 产生的噪声, 从而获得更准确的分割结果。

边界精度指标: 在表面距离指标上, UA-MT 的 95% HD 和 ASD 分别为 12.32 mm 和 3.27 mm。虽然提升幅度相对不大, 但依然优于 Standard MT。这说明不确定性感知机制有助于模型在复杂边界处做出更稳健的判断, 避免因盲目拟合错误伪标签而产生边界抖动。

3.5.2 消融实验

表 3.2 消融实验表格

实验组别	基础标注	未标注数据	核心机制	Dice (%)	Jaccard (%)	ASD (vox)	95HD (vox)
Baseline (基线)	16 样本	-	-	85.83	76.34	11.96	2.85
+ Semi-Sup (MT)	16 样本	64 样本	Mean Teacher	87.25	77.74	12.73	3.31
+ Uncertainty (UA-MT)	16 样本	64 样本	UA-MT	88.18	79.09	12.32	3.27
Upper Bound (参考)	80 样本	-	-	91.53	84.42	5.02	1.63

表3.2展示了不同设置下的实验结果。将仅用 16 个标注样本训练的全监督模型设为基线 (Baseline)，并在此基础上引入 Mean Teacher (MT) 及不确定性感知 (UA-MT) 机制，利用额外的 64 个未标注样本进行半监督训练。同时，使用 80 个标注样本训练的全监督模型作为性能上界 (Upper Bound)。

从数据可以看出，引入未标注数据对提升分割性能至关重要。相比于 Baseline，采用 MT 策略 (+ Semi-Sup) 后，Dice 系数由 85.83 提升至 87.25，Jaccard 系数增加了 1.4。这说明通过一致性正则化挖掘未标注数据的分布特征，确实能缓解小样本训练中的过拟合问题。不过，MT 模型在 ASD 和 95HD 指标上反而略有上升，暗示单纯的一致性约束虽然扩大了分割区域的覆盖，但在边界定位上可能引入了不稳定性。

针对边界不稳定的问题，UA-MT 模型通过引入不确定性加权机制进行了修正。实验数据显示，该模型将 Dice 进一步提升至 88.18，同时将 ASD 和 95HD 分别降低至 12.32 和 3.27。这种“重叠率上升、边界误差下降”的趋势表明，不确定性加权有效地筛选了高置信度区域，抑制了噪声样本对模型训练的干扰，使模型在关注难例样本的同时，能够更精准地拟合目标边界。

最后，虽然 UA-MT 在少样本场景下表现优异，但与 80 样本全监督的上界模型 (Dice 91.53) 相比，仍有约 3.35 的差距。这提示我们，尽管不确定性机制优化了数据利用率，但在极端少样本条件下，模型对复杂解剖结构的特征提取能力依然存在瓶颈，这也是后续工作需要突破的重点

第四章 基于 Transformer 的多尺度自适应表示学习模型

4.1 整体框架概述

在第三章中，我们通过引入认知不确定性解决了标注数据稀缺的问题，提升了模型在无标签数据上的鲁棒性。然而，分割性能的上限很大程度上取决于网络架构本身的特征提取能力。针对医学图像背景复杂、病灶边界模糊以及解剖结构多尺度变化的特点，单一的卷积神经网络（CNN）或纯粹的 Transformer 架构均存在各自的局限性。

为了构建具有强大多尺度自适应表示能力的分割模型，本章旨在探索并对比不同的“CNN + Transformer”融合范式。本章的总体研究框架遵循“局部细节提取 - 全局上下文建模 - 特征自适应融合”的技术路线：

1. 基础特征提取（CNN）：首先利用卷积神经网络（如 U-Net 的编码器）强大的局部特征提取能力，捕捉医学图像中的边缘、纹理等底层细节信息，弥补纯 Transformer 在低级视觉任务上的不足。

2. 全局依赖建模（Transformer）：随后，引入 Transformer 架构（包括 Swin Transformer 和标准 Vision Transformer），利用其自注意力机制捕获图像中的长距离依赖关系和全局上下文信息，解决传统卷积感受野受限导致的误分割问题。

3. 自适应特征增强（Attention Fusion）：最后，针对不同层级特征的重要性差异，在跳跃连接（Skip Connection）或瓶颈层引入通道与空间的双重注意力机制（Dual Attention），实现对多尺度特征的自适应筛选与加权，使模型更加聚焦于病灶区域。


基于上述框架，本章将系统性地构建并对比 Swin-Unet、TransUnet 以及改进的 DA-TransUnet 三种具体模型，以验证不同融合策略在多器官分割任务中的有效性。

4.2 基础模型选择（U - Net）

4.2.1 U-Net 结构解析

如图 4.1 所示，U-Net^[10]是一种经典的编码器-解码器结构网络，在医学图像分割领域表现相当出色。

从结构上看，它主要由编码器、解码器和跳跃连接三部分组成。编码器通过

图 4.1 U-Net 网络架构图^[10]


多次卷积和池化操作逐步降低特征图的空间分辨率，同时增加通道数，以提取更抽象的特征。解码器则通过上采样和卷积操作逐步恢复特征图的空间分辨率，并借助跳跃连接将编码器中对应层次的浅层特征与解码器中的深层特征融合在一起。

这种对称设计和跳跃连接的原理，让 U-Net 能够把高低层次的信息有效结合起来，在分割任务中既保留细节信息，又不失对全局上下文的理解。另外，U-Net 结构简单、效率高，这也是它在医学图像分割领域被广泛使用的重要原因，尤其是在处理复杂的解剖结构时表现更为突出。

4.2.2 U-Net 的优势与局限

U-Net 在处理医学图像时有不少明显的优势，其中最突出的是它对多尺度特征的捕捉能力。通过编码器中的多次下采样，U-Net 能提取不同分辨率下的特征信息，从而适应不同大小的目标区域。此外，跳跃连接机制让网络在解码过程中能充分利用浅层特征中的细节信息，这对精确分割医学图像中的细小结构尤其重要。

不过，U-Net 在建模长距离依赖关系方面存在一定短板。因为它主要靠卷积操作来提取特征，而卷积的感受野有限，所以很难有效捕捉图像中的全局上下文信息。这个局限在处理空间分布复杂的大病灶或大器官时尤其明显，分割结果里容易出现过分割或欠分割的问题。另外，当训练数据和测试数据中的目标体积大小

图 4.2 Swin - Unet 模型架构图^[11]

差异较大时，U-Net 由于结构相对简单、参数较少，难以自适应地完成训练和推理。

4.3 Transformer 引入与融合策略

4.3.1 Swin - Unet 模型

如图 4.2 所示，Swin-Unet^[11]模型是一种把 Swin Transformer 模块融入 U-Net 架构的尝试，目的是借助自注意力机制来增强模型对多尺度特征的捕捉能力。

具体来看，Swin-Unet 在编码器部分采用了基于窗口的自注意力机制 (Window-based Self-Attention)。这种机制先把特征图划分成多个不重叠的窗口，然后在每个窗口内单独计算自注意力，这样既显著降低了计算复杂度，又没有丢掉对长距离依赖的建模能力。此外，Swin-Unet 还引入了移位窗口策略 (Shifted Window)，用




Fig. 2. Swin transformer block.

图 4.3 Swin Transformer 模块结构图^[11]

来加强不同窗口之间的信息交流，进一步优化多尺度特征的提取效果。至于跳跃连接等其他部分，基本是参考 U-Net 的做法来设计的。

1. Patch Partition + Linear Embedding:

这部分主要是将原图片的输入转化为 Transformer 接受的格式。即通过 Patch 划分以及线性映射将 $W \times H \times C$ 的图像转变为 $W/4 \times H/4 \times C/4$ 。

2. Swin Transformer Block 模块:

这部分为核心模块，在下文中详细介绍。

3. Patch Merging:

这部分主要是将得到的图像再次进行压缩。

即将大小为 $W \times H \times C$ 的图像通过合并以及线性映射的方式，合并相邻 2×2 范围内的像素，而后通过线性映射将通道压缩为 $1/2$ 。

具体格式转换为 $W \times H \times C \rightarrow W/2 \times H/2 \times C/2$ 。

Swin Transformer 内部具体具体工作方式，如图 4.3 所示：

上半部分：基于窗口的多头自注意力模块

1. 层归一化：输入特征 z^{l-1} 首先经过层归一化处理，这有助于稳定训练过程。

2. 基于窗口的多头自注意力：这是核心计算单元。特征图被划分为若干不重叠的局部窗口，自注意力计算仅在每个窗口内部独立进行。其计算公式为：

$$\hat{z}^l = \text{W-MSA}(\text{LN}(z^{l-1})) + z^{l-1} \quad (4-1)$$

这里使用了残差连接，将 W-MSA 的输出与原始输入 z^{l-1} 相加，有助于梯度

反向传播。

3. 多层感知机：中间输出 $\hat{z}^l$ 再次经过层归一化，然后进入多层感知机。最终输出为：

$$z^l = \text{MLP}(\text{LN}(\hat{z}^l)) + \hat{z}^l \quad (4-2)$$

下半部分：基于窗口的多头自注意力模块

1. 层归一化：输入 z^l 经过层归一化。

2. 基于移位窗口的多头自注意力：这是 Swin Transformer 的精髓。相比于上半部分的规则窗口，这里的窗口划分向右下方移动了半个窗口的大小。这种移位操作使得新的窗口跨越了上一轮的窗口边界，从而在连续模块之间建立起跨窗口的连接。其计算公式为：

$$z^{l+1} = \text{SW-MSA}(\text{LN}(z^l)) + z^l \quad (4-3)$$

3. 多层感知机：最后，经过残差连接后的特征再次进入多层感知机进行非线性变换，得到最终输出：

$$z^{l+2} = \text{MLP}(\text{LN}(z^{l+1})) + z^{l+1} \quad (4-4)$$

通过这种基于窗口的多头自注意力 + 基于移位窗口的多头自注意力的交替结构，Swin Transformer 既保持了局部计算的高效性（线性复杂度），又通过移位窗口机制逐步捕获了全局的上下文信息。

4.3.2 TransUnet 模型

如图 4.4 所示，TransUNet^[12]是医学图像分割领域中第一个把 Transformer 引入 U-Net 架构的工作，算得上开创性的尝试。与 Swin-Unet 那种全 Transformer 结构不同，TransUNet 采用的是一种“CNN-Transformer 混合架构”。

这种设计的核心思路是取两者之长：一边用 CNN（如 ResNet）强大的局部特征提取能力来补上 Transformer 在底层细节方面的短板，另一边用 Transformer 的全局自注意力机制来解决 CNN 感受野有限、抓不住长距离依赖的问题。

整个框架的结构：

1. CNN 编码器：

这部分主要用于提取图像的局部特征。不同于直接将原图切块，TransUNet 首先使用一个标准的 CNN 作为主干网络。




Fig. 1: Overview of the framework. (a) schematic of the Transformer layer; (b) architecture of the proposed TransUNet.

图 4.4 TransUnet 模型结构图^[12]

具体来说，它将 $W \times H \times C$ 的图像通过卷积层和下采样层，转化为一个尺寸较小但通道数很深的特征图。

2. Linear Projection

这部分是将 CNN 提取的特征图转化为 Transformer 能够处理的序列格式。这部分在 Swin-Unet 中已经提及，作用相近。

3. Transformer 编码器

这是模型的核心，用于捕捉全局上下文信息。输入是上述生成的特征序列。通过多层 Transformer Layer，让序列中的每一个 Patch 都能与序列中其他所有 Patch 进行交互，从而建立全图的长距离依赖关系。

Transformer Layer 内部具体具体工作方式：

上半部分：自注意力模块



1. 层归一化：输入特征 z^{l-1} 首先经过层归一化处理，这有助于稳定训练过程。

2. 基于窗口的多头自注意力：这是核心计算单元。特征图被划分为若干不重叠的局部窗口，自注意力计算仅在每个窗口内部独立进行。其计算公式为：

$$\hat{z}^l = \text{MSA}(\text{LN}(z^{l-1})) + z^{l-1} \quad (4-5)$$

这里使用了残差连接，将 MSA 的输出与原始输入 z^{l-1} 相加，有助于梯度反向传播。

下半部分：基于窗口的多头自注意力模块

图 4.5 DA - TransUNet 模型结构图^[13]图 4.6 DA-Block 模块结构图^[13]

1. 层归一化：输入 z^l 经过层归一化。
2. 多层感知机：中间输出 z^l 再次经过层归一化，然后进入多层感知机。最终输出为：

$$z^{l+1} = \text{MLP}(\text{LN}(z^l)) + z^l \quad (4-6)$$

通过这种“CNN 提取局部特征 + Transformer 建立全局依赖”的混合结构, TransUNet 既保留了 CNN 对医学图像边缘和纹理的敏感度, 又引入了 Transformer 的全局建模能力, 有效缓解了传统 U-Net 在处理复杂解剖结构时的不足。不过, 由于它对全局所有单元都进行注意力计算, 导致参数量偏大、计算复杂度高、运行时间也比较长。

4.3.3 DA - TransUNet 改进模型

如图 4.5 所示, DA-TransUNet^[13]是在 TransUNet 基础上改进的一种架构, 目的是通过引入双重注意力机制来进一步提升医学图像分割的精度。




Figure 3: Architecture of Position Attention Mechanism(PAM).

图 4.7 PAM 模块结构图^[13]

具体来看，DA-TransUNet 在原有的 CNN 编码器与 Transformer 编码器之间，以及在跳跃连接路径上，嵌入了专门设计的 DA-Block。这种机制能同时在空间维度和通道维度上对特征进行加权，从而让模型更专注于病灶区域的细节特征，同时抑制无关背景的干扰。相比 Swin-Unet 那种基于窗口的注意力机制，DA-TransUNet 更强调对特征进行显式的校准。

整个框架的结构与 TransUnet 相近，只有跳跃连接的部分进行了改进。

故仅对跳跃连接处进行说明：

1. 输入与通道降维：

对应途中的 Conv 块，将通道数压缩为 $n/16$ 。

2. 分支一：位置注意力模块 PAM：

如图 4.7，该模块旨在生成一个空间注意力图，表示任意两个单元之间的影响。

该模块首先会让输入分别经过三个卷积层，而后生成特征图 B、C、D，它们均被重塑为 $C \times N$ 的矩阵，以便计算位置间的相关性。

接着进行空间注意力图计算，主要通过矩阵乘法以及 Softmax 归一化函数完成：

$$S_{ji} = \frac{\exp(B_i \cdot C_j)}{\sum_{i=1}^N \exp(B_i \cdot C_j)} \quad (4-7)$$

其中 S_{ji} 表示第 i 个位置对第 j 个位置的影响程度（即注意力权重）。

最后将注意力图的转置与特征图 D 进行矩阵乘法，并将结果重塑为原形状。




Figure 4: Architecture of Channel Attention Mechanism(CAM).

图 4.8 CAM 模块结构图^[13]

在结尾处加入残差连接：

$$E_j = \alpha \sum_{i=1}^N (S_{ji} D_i) + A_j \quad (4-8)$$

3. 分支二：通道注意力模块 CAM：

如图 4.8，这是 CAM，它在提取通道特征发面表现优异，与 PAM 不同，直接将原始特征 $C \times H \times W$ 重塑为 $C \times N$ ，然后对 A 和其转置进行矩阵乘法，接下来，使用一个 Softmax 层以获得通道注意力图。

4. 特征融合与输出：

将上方支路和下方支路进行加权求和后，最后通过一个 Conv 层将图像恢复到目标大小以及通道数。

4.4 实验设计

4.4.1 数据集与预处理

本实验采用 Synapse 多器官分割数据集进行验证。该数据集包含腹部 CT 扫描图像，涵盖了胃、肾脏、脾脏、肝脏等 8 个主要器官以及背景，共计 9 个类别。

针对该数据集，进行了以下预处理：

图像重采样与裁剪：为了适配 Transformer 架构的输入要求，要将所有原始切片统一调整为 224×224 的分辨率。

数据增强：在训练阶段，采用了随机旋转、翻转等在线增强策略，以增加样本的多样性，提升模型的泛化能力。

标准化：对图像像素强度进行归一化处理，消除不同扫描设备带来的分布差

异。

4.4.2 训练策略

实验基于 PyTorch 框架,对比了四种不同的网络架构:UNet、TransUNet、Swin-Unet 以及 DA-TransUNet。

所有模型均在相同的超参数配置下进行训练,以确保对比的公平性,具体训练参数设置如下:

优化器: Adam, 利用其自适应学习率特性加速收敛。

学习率策略: 初始学习率设为 0.01。为了平衡不同批次大小对梯度的影响,实验中根据公式 $\text{base_lr} = \text{base_lr} * (\text{batch_size} / 24)$ 对学习率进行了调整,使其根据不同的 batch_size 自适应调整学习率。

Batch Size: 受硬件性能影响,每批次处理图像数量设为 12。

迭代次数: 最大训练迭代次数设为 30,000 次 ($\text{max_iterations}=30000$), 最大训练轮数设为 200。

输入尺寸: 网络输入图像尺寸固定为 224×224 。

4.5 对比与结果分析

4.5.1 不同模型检测性能对比实验分析

为了全面评估分割性能,实验采用了四个广泛使用的评价指标:

1. Dice 相似系数 (Dice Coefficient): 衡量分割重叠度,值越大越好。
2. 95% 豪斯多夫距离 (95% HD): 衡量表面最大不一致距离,值越小越好。

表 4.1 不同模型架构在测试集上的性能对比

模型架构	Dice(%)	95HD(mm)
UNet	76.12	39.10
TransUNet	76.69	24.61
Swin-Unet	77.93	31.09
DA-TransUNet	80.67	26.06

结果分析:

基线模型表现: UNet 作为纯卷积网络, Dice 系数达到 0.7612,但在边界距离指标上 ($\text{HD}_{95}=39.10$) 表现一般,说明它在捕捉长距离依赖和精确定位边界方面存在不足。

Transformer 的引入: TransUNet 虽然加入了全局注意力机制,但在本实验设

置下，其 Dice 系数 (0.7669) 只比 UNet 高一点点，不过 HD95 (24.61) 明显优于 UNet，这说明 Transformer 结构对改善边缘分割的准确性是有帮助的。

纯 Transformer 架构：Swin-Unet 表现出了较强的特征提取能力，Dice 系数达到 0.7793，超过了前两者，证明了基于滑动窗口的自注意力机制在处理医学图像纹理细节方面确实有优势。

两种 Transformer 架构的对比：对比这两种主要使用 Transformer 结构的模型，TransUNet 在边缘分割准确性上效果更好，而 Swin-Unet 在图像重合度方面更胜一筹。不过，TransUNet 需要训练的参数量更大，所以耗时远高于 Swin-Unet。在实际应用中，应根据具体需求来权衡选择。

DA-TransUNet 的表现：DA-TransUNet 在 TransUNet 基础上进一步引入了注意力模块。从实验结果看，它的 Dice 精度更高，边缘分割准确度则与 TransUNet 相近，整体表现不错。

4.5.2 消融实验分析

表 4.2 消融实验表格

模型架构	ViT	Swin	DA	Dice(%)	95HD(mm)
UNet (Baseline)	-	-	-	76.12	39.10
TransUNet	✓	-	-	76.69	24.61
Swin-Unet	-	✓	-	77.93	31.09
DA-TransUNet (Ours)	✓	-	✓	80.67	26.06

首先，以标准 UNet 作为 Baseline，它在测试集上的 Dice 分数为 76.12%，95HD 为 39.10mm。引入 Vision Transformer (ViT) 模块构建 TransUNet 后，模型的表现出现了分化：Dice 分数小幅涨到 76.69%，但 95HD 明显降到了 24.61mm。这说明全局自注意力机制确实改善了模型的宏观定位能力，不过在捕捉精细边界时可能存在过平滑的问题。

再进一步，引入 Swin Transformer 模块后 (Swin-Unet)，模型在保持较低 95HD 的同时，Dice 分数提升到了 77.93%。这验证了基于移位窗口的自注意力机制在保留局部细节特征方面的优势。

最后是 DA-TransUNet。我们在保留 ViT 全局建模能力的基础上，额外加入了 Dual Attention 模块。这个配置取得了整体最佳的表现 (Dice 80.67%，95HD 26.06mm)。值得注意的是，相比单独使用 ViT，加入 Dual Attention 后 Dice 分

数有了明显的跳跃式增长。这也证明 Dual Attention 模块能有效弥补纯 Transformer 架构在局部细节捕捉上的不足——通过通道注意力和空间注意力的配合，实现了全局语义与局部纹理的深度融合。

第五章 总结与展望

医学图像分割是计算机辅助诊断系统中的关键一环，其分割精度直接影响医生的诊断效率和治疗方案。针对医学图像标注成本高、传统卷积神经网络在长距离依赖建模上的局限，本文分别从半监督学习策略和网络架构改进两个角度展开了研究。具体来说，先引入认知不确定性机制来利用大量无标签数据，再设计基于双重注意力机制的 Transformer 混合架构来提升分割性能。

5.1 论文所完成的工作

本文围绕医学图像分割中的几个关键问题，主要完成了以下工作：

1. 对深度学习在医学图像分割中的应用进行了系统性综述：

详细讨论了从全监督学习到半监督学习的范式转变，分析了 CNN 与 ViT 各自的优缺点。重点探讨了 Mean Teacher 框架和认知不确定性理论在小样本标注问题上的理论依据，为后续研究打下基础。

2. 提出了基于认知不确定性的半监督分割方法 (UA-MT)

针对医学图像标注稀缺的问题，搭建了 UA-MT 框架。

机制引入：在 3D V-Net 的解码器里加入 Dropout 层，用蒙特卡洛采样来估算模型的认知不确定性。

策略优化：在 Mean Teacher 架构基础上，设计了不确定性加权的一致性损失函数，降低无标签数据中不可靠区域的干扰。

实验验证：在 Synapse 数据集上的实验表明，该方法仅需少量有标签数据（如 16 例）配合大量无标签数据，就能达到接近全监督模型的性能。

3. 构建了基于 Transformer 的多尺度自适应表示学习模型 (DA-TransUNet)

针对纯 CNN 感受野受限、纯 Transformer 容易丢失局部细节的问题，本文深入研究了 Swin-Unet 和 TransUNet 架构，并在此基础上提出了改进模型 DA-TransUNet。

架构融合：采用 CNN 与 Transformer 混合编码策略，既保留 CNN 提取局部特征的能力，又借助 Transformer 捕获全局上下文信息。

双重注意力机制：在跳跃连接或瓶颈层引入双重注意力模块，增强模型对多尺度特征的自适应表达能力。

性能提升：实验结果显示，DA-TransUNet 在 Synapse 多器官分割任务中，Mean Dice 达到 80.67%，HD95 显著降低，优于 UNet、Swin-Unet 和 TransUNet 等主流模型。

4. 完成了全面的对比实验与结果分析

在 Synapse 数据集上实施了严格的预处理和训练策略。通过定量指标（Mean Dice, Mean HD95）和定性可视化结果，充分验证了本文方法在处理复杂器官形态和边界模糊问题上的有效性。

5.2 问题与不足

虽然本文方法在一定程度上提升了医学图像分割的精度，但受限于实验环境和算法复杂度，仍存在以下几点不足：

1. 计算资源消耗较大

引入 Transformer 架构（尤其是 Swin-Unet 和 DA-TransUNet）明显增加了模型的参数量和计算复杂度。训练时相比传统 UNet，显存占用更高、推理时间更长，这在一定程度上限制了其在实时临床环境中的部署。

2. 超参数敏感性

UA-MT 方法中，不确定性阈值的设定以及一致性损失的权重系数对最终结果影响较大。目前主要靠经验来调，缺乏自适应的调节机制。DA-TransUNet 中，注意力模块的引入也扩大了超参数搜索的空间。

3. 小器官分割仍存在误差

从实验结果（如 HD95 指标）来看，虽然平均指标有所提升，但对于体积较小或形态变化剧烈的器官（如胆囊、胰腺），模型仍然存在漏检或边界分割不准的情况。这可能与数据集的类别不平衡以及 CT 图像的切片厚度有关。

4. 数据模态单一

本文只在腹部 CT 数据集和左心房 CA 数据集上做了验证，没有涉及 MRI 或其他模态的医学图像。不同模态的图像特性差异较大，本文模型的跨模态泛化能力还需要进一步检验。

5.3 前景与展望

基于本文的研究工作与存在的不足，未来的研究可以从以下几个方向展开：

1. 模型轻量化与加速

为了让深度学习模型更好地落地临床，未来可以研究基于知识蒸馏或模型剪枝的技术，压缩 Transformer 架构的参数量。同时探索轻量化注意力机制（如线性注意力）在医学分割中的应用，在保证精度的前提下大幅提升推理速度。

2. 引入自监督预训练

目前的实验主要依赖随机初始化或 ImageNet 预训练权重。未来可以尝试在大规模无标签医学数据上做自监督预训练（如 MAE、SimMIM），学习更具鲁棒性的特征表示，从而进一步提升半监督学习的效果。

3. 多模态融合与三维连续性建模

目前的 DA-TransUNet 主要基于 2D 切片处理，忽略了层间的空间连续性。未来可以尝试把模型扩展到 3D 版本，并探索 CT 和 MRI 等多模态数据的融合分割，利用不同模态的互补信息提升分割精度，尤其是小器官的分割性能。

4. 交互式分割与临床辅助

结合本文的不确定性估计能力，开发人机交互式分割系统。当模型对某些区域预测不确定性较高时，自动提示医生进行点击或涂鸦修正，实现“人在回路”的高效精准分割，更好地服务于临床诊断。

致 谢

随着本文的完成，我四年的大学生活也将画上句号。回首在西安电子科技大学学习的这段时光，可以说是自己专业知识积累最扎实、专业能力提升最快的一个阶段。从大一对编程一知半解，到如今能够独立完成一项完整的研究工作，这期间的成长离不开学校提供的学习环境和老师们的悉心教导。除此之外，校园里的集体生活也让我慢慢学会了如何融入团队、如何与人有效沟通、如何面对和化解矛盾、如何在压力下调整心态并不断提升自己。这些收获，或许和专业知识一样宝贵。

感谢权老师在整个毕业设计阶段对我的耐心指导。每当我遇到技术难题或思路卡壳时，您总能帮我理清方向，指出合适的解决路径，并提出许多中肯的意见和建议，让我少走了不少弯路。感谢实验室的学长，在我一开始完全不知道从哪儿下手的阶段，主动给我推荐了经典文献，耐心讲解论文的核心要点，还给出了许多具体的改进思路。最后，由衷感谢我的家人。你们一直以来的鼓励和支持，是我能够坚持走到最后、完成这篇论文的不竭动力。

参考文献

- [1] LUO X, CHEN J, SONG T, et al. Semi-supervised medical image segmentation through dual-task consistency[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 35: 10. 2021: 8801-8809.
- [2] LI S, ZHANG C, HE X. Shape-aware semi-supervised 3D semantic segmentation for medical images[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2020: 552-561.
- [3] GU R, WANG G, SONG T, et al. CA-Net: Comprehensive attention convolutional neural networks for explainable medical image segmentation[J]. IEEE transactions on medical imaging, 2020, 40(2): 699-711.
- [4] BAI X, HU Z, ZHU X, et al. Transfusion: Robust lidar-camera fusion for 3d object detection with transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 1090-1099.
- [5] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[J]. Advances in neural information processing systems, 2017, 30.
- [6] BERTHELOT D, CARLINI N, GOODFELLOW I, et al. Mixmatch: A holistic approach to semi-supervised learning[J]. Advances in neural information processing systems, 2019, 32.
- [7] HATAMIZADEH A, TANG Y, NATH V, et al. Unetr: Transformers for 3d medical image segmentation[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2022: 574-584.
- [8] ISENSEE F, PETERSEN J, KLEIN A, et al. nnU-Net: Self-adapting framework for U-Net-based medical image segmentation[J]. arXiv preprint arXiv:1809.10486, 2018.
- [9] YU L, WANG S, LI X, et al. Uncertainty-aware Self-ensembling Model for Semi-supervised 3D Left Atrium Segmentation[J/OL]. ArXiv, 2019, abs/1907.07034. <https://api.semanticscholar.org/CorpusID:196831348>.
- [10] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J/OL]. ArXiv, 2015, abs/1505.04597. <https://api.semanticscholar.org/CorpusID:3719281>.
- [11] CAO H, WANG Y, CHEN J, et al. Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation[C/OL]//ECCV Workshops. 2021. <https://api.semanticscholar.org/CorpusID:234469981>.
- [12] CHEN J, LU Y, YU Q, et al. TransUNet: Transformers Make Strong Encoders for Medical Image

- Segmentation[J/OL]. ArXiv, 2021, abs/2102.04306. <https://api.semanticscholar.org/CorpusID:231847326>.
- [13] SUN G, PAN Y, KONG W, et al. DA-TransUNet: integrating spatial and channel dual attention with transformer U-net for medical image segmentation[J/OL]. Frontiers in Bioengineering and Biotechnology, 2023, 12. <https://api.semanticscholar.org/CorpusID:264305997>.